Tarea evaluable CE_5075 4.1

Big data aplicado



Índice

1 IMPORTAR DATOS	3
2 PREGUNTAS SOBRE LOS DATOS	6
1. Llistat dels 10 programes de TV amb més d'una temporada que tenen millor valoració, ordenats per valoració en ordre decreixent.	
	6
2. Llistat dels 10 anys en què els seus programes de TV (segons l'any de llançament) han tengut més vots, ordenats per nombre de vots, en ordre decreixent.	
	7
3. Llistat dels 10 directors amb més pel·lícules, ordenats per nombre de pel·lícules en ordre decreixent.	8
•	
4. Llistat dels 10 actors amb millor valoració mitjana de les seves pel·lícules, ordentats per valoració mitjana en ordre decreixent.	9

APARTADO 1 - Películas i programas de Netflix

En la actividad de aprendizaje de la entrega 3 (y en algunos ejemplos de esta entrega), trabajamos con el conjunto de datos de las películas y programas de TV mejor valorados de Netflix, que se puede encontrar en Kaggle.

Recordemos que de los seis archivos que componen el conjunto de datos, solo nos interesan dos:

- raw_titles.csv, que contiene la información de las películas (movies) y programas de TV (shows), incluyendo las series de la plataforma Netflix, con el número de votos y puntuación en IMDb.
- raw_credits.csv, que contiene la información de los actores y directores de todas las películas y programas.

Nota: También puedes descargar los archivos desde el repositorio del curso, donde ya se han utilizado tabuladores como separadores de campos para evitar problemas con las importaciones: <u>raw_titles.csv</u> y <u>raw_credits.csv</u>.

Como analistas de datos, nos han solicitado responder una serie de preguntas utilizando **Apache Impala**, ya sea desde **Hue** o desde el **Shell**.

1 IMPORTAR DATOS

Se han importado los datos desde el repositorio del curso ofrecido por el enunciado:

wget https://raw.githubusercontent.com/tnavarrete-iedib/bigdata-24-25/refs/heads/main/raw titles.csv

wget https://raw.githubusercontent.com/tnavarrete-iedib/bigdata-24-25/refs/heads/main/raw credits.csv

Lo siguiente ha sido compartir los archivos en Hadoop:

```
hdfs dfs -mkdir netflix_movies
hdfs dfs -put raw_titles.csv netflix_movies/
hdfs dfs -put raw credits.csv netflix movies/
```

```
cloudera@quickstart.cloudera ~/tarea_4 (11.424s)
hdfs dfs -mkdir netflix_movies

cloudera@quickstart.cloudera ~/tarea_4 (13.771s)
hdfs dfs -put raw_titles.csv netflix_movies/

cloudera@quickstart.cloudera ~/tarea_4 (14.343s)
hdfs dfs -put raw_credits.csv netflix_movies/

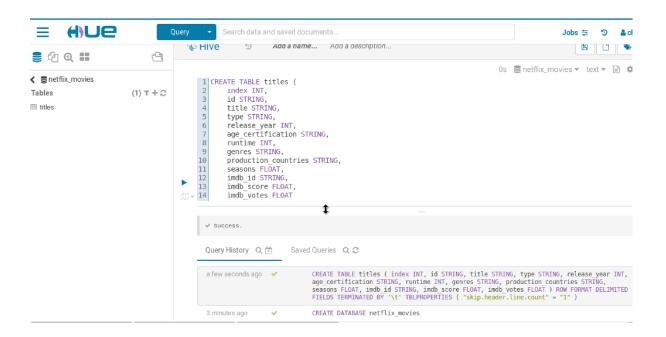
cloudera@quickstart.cloudera ~/tarea_4 (11.714s)
hdfs dfs -ls netflix_movies/

Found 2 items
-rw-r--r- 1 cloudera cloudera
-rw-r--r- 1 cloudera cloudera
-rw-r--r- 1 cloudera cloudera
-farea_4 (11.714s)
-farea_4 (11.714s)
-farea_4 (11.714s)
-farea_5 (11.714s)
-farea_6 (11.714s)
-farea_6 (11.714s)
-farea_7 (11.714s)
-farea_7 (11.714s)
-farea_8 (11.714s)
-farea_9 (11.7
```

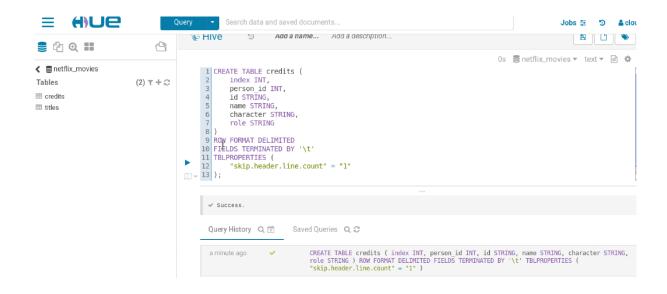
El siguiente paso ha sido crear las tablas e importar los datos de los csv en Hive a través de los siguientes comandos:

CREATE DATABASE netflix movies;

```
CREATE TABLE titles (
    index INT,
    id STRING,
    title STRING,
    type STRING,
    release year INT,
    age certification STRING,
    runtime INT,
    genres STRING,
    production countries STRING,
    seasons FLOAT,
    imdb id STRING,
    imdb score FLOAT,
    imdb votes FLOAT
ROW FORMAT DELIMITED
FIELDS TERMINATED BY '\t'
TBLPROPERTIES (
    "skip.header.line.count" = "1"
);
```

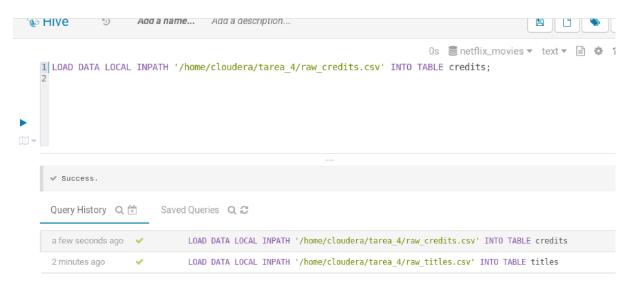


```
CREATE TABLE credits (
    index INT,
    person_id INT,
    id STRING,
    name STRING,
    character STRING,
    role STRING
)
ROW FORMAT DELIMITED
FIELDS TERMINATED BY '\t'
TBLPROPERTIES (
    "skip.header.line.count" = "1"
);
```



LOAD DATA LOCAL INPATH '/home/cloudera/tarea_4/raw_titles.csv' INTO TABLE titles;

LOAD DATA LOCAL INPATH '/home/cloudera/tarea_4/raw_credits.csv' INTO TABLE credits;



Por último, se crean las tablas para tener los datos en Impala, se ha decidido usar el formato parquet:

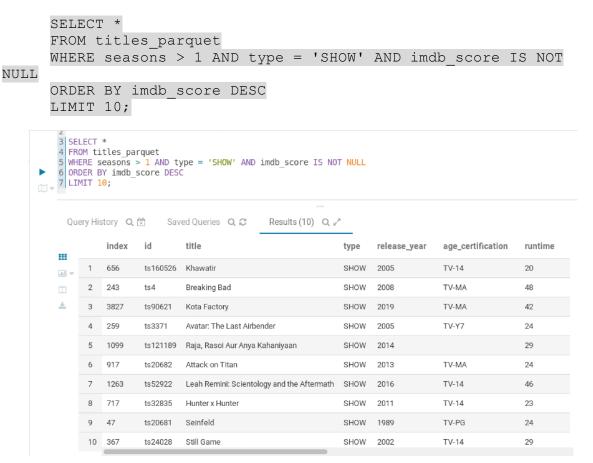
```
CREATE TABLE titles_parquet
STORED AS PARQUET
AS SELECT * FROM titles;

CREATE TABLE credits_parquet
STORED AS PARQUET
AS SELECT * FROM credits;
```

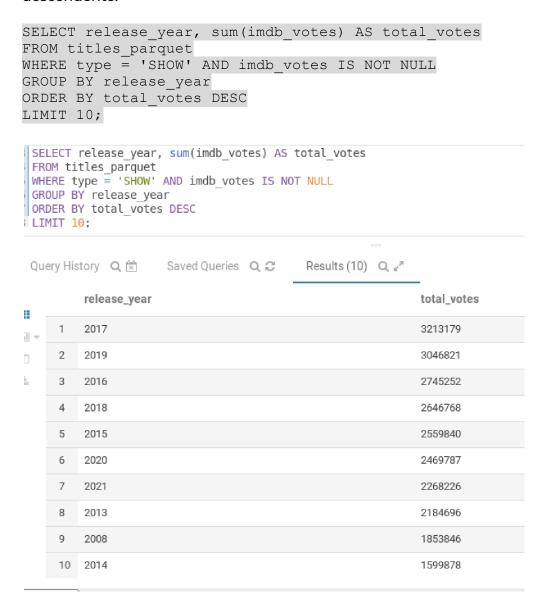


2 PREGUNTAS SOBRE LOS DATOS

 Listado de los 10 programas de TV con más de una temporada que tienen mejor valoración, ordenados por valoración en orden descendente.



2. Listado de los 10 años en los que sus programas de TV (según el año de lanzamiento) han tenido más votos, ordenados por número de votos en orden descendente.



3. Listado de los 10 directores con más películas, ordenados por número de películas en orden descendente.



4. Listado de los 10 actores con mejor valoración media de sus películas, ordenados por valoración media en orden descendente.

```
SELECT credits.name, AVG(titles.imdb score) AS imdb avg
FROM credits parquet AS credits
JOIN titles parquet AS titles ON credits.id = titles.id
WHERE credits.`role` = 'ACTOR' AND titles.imdb score IS NOT
NULL
GROUP BY credits.name
ORDER BY imdb avg DESC
LIMIT 10;
3|SELECT credits.name, AVG(titles.imdb score) AS imdb avg
 4 FROM credits parquet AS credits
 5 JOIN titles parquet AS titles ON credits.id = titles.id
 6 WHERE credits.`role` = 'ACTOR' AND titles.imdb score IS NOT NULL
7 GROUP BY credits.name
 8 ORDER BY imdb avg DESC
9 LIMIT 10:
 Query History Q 🖄 Saved Queries Q 😅
                                           Results (10) Q 2
          name
                                                  imdb_avg
-
          Anna Gunn
                                                  9.5
dd v
          Betsy Brandt
                                                  9.5
      2
\Box
£
          Cricket Leigh
                                                  9.3000001907348633
      4
         Zach Tyler
                                                  9.3000001907348633
         Jessie Flower
                                                  9.3000001907348633
         Zhang Feng Yi
                                                  9.1999998092651367
      7
         Lee Hye-ri
                                                  9.1999998092651367
      8
         Lee Ji-ah
                                                  9.1999998092651367
         He Kailang
                                                  9.1999998092651367
      10 Kim Sung-kyun
                                                  9.1999998092651367
```