Tarea evaluable 3.1

Big data aplicado



Índice

APARTADU 1	2
1 - Importación de datos:	2
2 - Querys:	5
2.1 Número de goles que ha marcado Lionel Messi (sin contar autogoles).	5
2.2 Listado de los 5 partidos más recientes que ha jugado la selección españo	ola.
2.3 Número de goles que ha marcado España en toda su historia. Esta información debe extraerse de results, ya que goalscorers no contiene todos goles.	los 7
 2.4 Listado de los 5 máximos goleadores con la selección española (sin conta autogoles). 	ar 8
 2.5 Listado de los jugadores españoles que han marcado algún gol de penalt alguna Eurocopa (UEFA Euro), ordenados alfabéticamente. 	i en 9
2.6 Listado de los 5 máximos goleadores de las fases finales de los Mundiales (FIFA World Cup) (sin contar autogoles).	s 10
APARTADO 2	11
1 - Importación de datos:	11
2 - Querys:	15
2.1 ¿Cuál de las plataformas tiene más películas en su colección? Muestra la plataforma y el número de películas.	15
2.2 ¿Cuál de las plataformas tiene más películas en su colección? Muestra la plataforma y el número de películas.	16
2.3 ¿Cuál de las plataformas tiene más películas en su colección? Muestra la plataforma y el número de películas.	17
2.4 ¿Cuál de las plataformas tiene más películas en su colección? Muestra la plataforma y el número de películas.	18

APARTADO 1

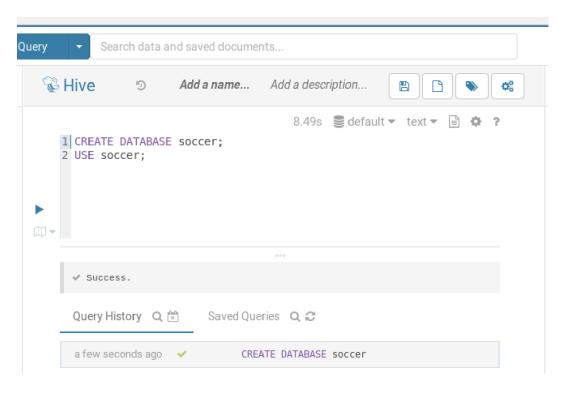
Vamos a trabajar con el dataset de resultados de todos los partidos de fútbol disputados entre selecciones nacionales desde 1872 hasta la actualidad, que se puede encontrar en Kaggle, donde podrás encontrar todos los detalles. De los tres archivos que componen el dataset, nos interesan sólo dos:

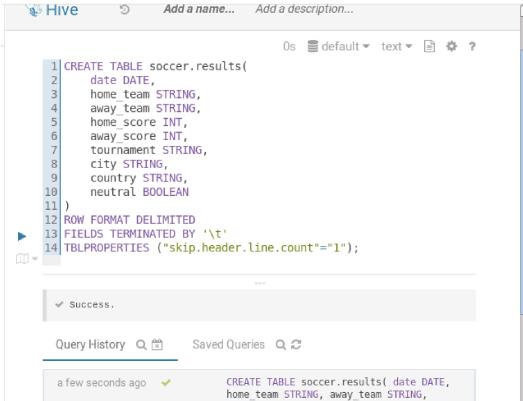
- **results.csv,** que contiene la información de todos los partidos disputados, incluyendo los equipos, el marcador, el campeonato y la sede.
- **goalscorers.csv**, que contiene la información de todos los goles marcados en estos partidos. Para cada gol, se indica el partido (fecha y equipos), el equipo y jugador que marca el gol, el minuto y dos flags que indican si ha sido en propia puerta o de penalti.

1 - Importación de datos:

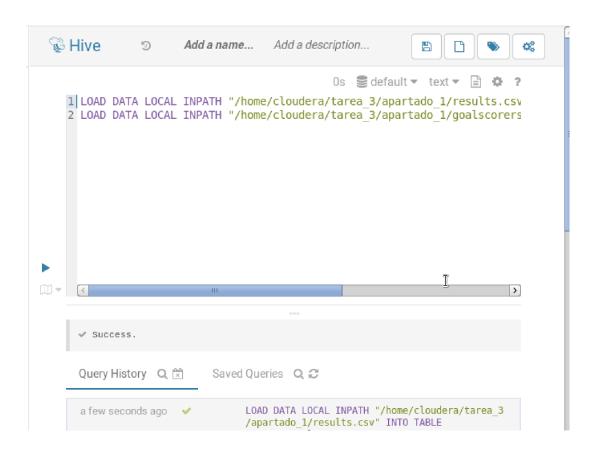
A través del comando *wget* he descargado los datos con el link ofrecido en los apuntes.

Después de importar los datos creamos la BBDD y las tablas que contendrán los archivos. El siguiente paso ya será cargar los datos en la BBDD de Hive.





```
Hive
                                                                                                                           Add a name... Add a description...
                                                                                                                                                                                                                                  Os Sedefault v text v v 
                           1 CREATE TABLE soccer.goalscorers(
                                                              date STRING,
                            3
                                                              home team STRING,
                                                             away_team STRING,
team STRING,
                            4
                            5
6
                                                              scorer STRING,
                             7
                                                             minute INT,
                            8
                                                             own goal BOOLEAN,
                            9
                                                              penalty BOOLEAN
                       10)
                       11 ROW FORMAT DELIMITED
                                       FIELDS TERMINATED BY '\t'
                      13 TBLPROPERTIES ("skip.header.line.count"="1");
₩ -
                                    ✓ Success.
                                 Query History Q 🛱
                                                                                                                                                      Saved Queries Q 2
                                                                                                                                                                                  CREATE TABLE soccer.goalscorers(
                                   a few seconds ago - -
                                                                                                                                                                                  date STRING. home team STRING.
```



```
CREATE TABLE soccer.results (
    date DATE,
    home team STRING,
    away team STRING,
    home_score INT,
    away_score INT,
    tournament STRING,
    city STRING,
    country STRING,
   neutral BOOLEAN
)
ROW FORMAT DELIMITED
FIELDS TERMINATED BY '\t'
TBLPROPERTIES ("skip.header.line.count"="1");
CREATE TABLE soccer.goalscorers (
    date STRING,
    home team STRING,
    away_team STRING,
    team STRING,
    scorer STRING,
   minute INT,
    own_goal BOOLEAN,
    penalty BOOLEAN
ROW FORMAT DELIMITED
FIELDS TERMINATED BY '\t'
TBLPROPERTIES ("skip.header.line.count"="1");
```

```
LOAD DATA LOCAL INPATH
"/home/cloudera/tarea_3/apartado_1/results.csv" INTO TABLE soccer.results;

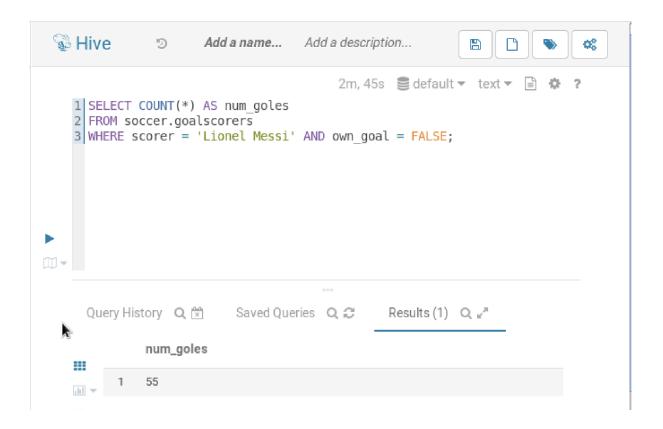
LOAD DATA LOCAL INPATH
```

"/home/cloudera/tarea_3/apartado_1/goalscorers.csv" INTO TABLE soccer.goalscorers;

2 - Querys:

2.1 Número de goles que ha marcado Lionel Messi (sin contar autogoles).

```
SELECT COUNT(*) AS num_goles
FROM soccer.goalscorers
WHERE scorer = 'Lionel Messi' AND own_goal = FALSE;
```



2.2 Listado de los 5 partidos más recientes que ha jugado la selección española.

```
SELECT *
FROM soccer.results
WHERE home_team = 'Spain' OR away_team = 'Spain'
ORDER BY date DESC
LIMIT 5;
                                                                                                  2m, 59s ■ default v text v 🖹 🌣 ?
  1 SELECT *
2 FROM soccer.results
3 WHERE home team = 'Spain' OR away_team = 'Spain'
4 ORDER BY date DESC
5 LIMIT 5;
                                                                                                    I
   Query History Q 🛱
                      Saved Queries Q @ Results (5) Q ...*
           results.date results.home_team results.away_team results.home_score results.away_score results.commament results.city
      1 2024-11-18
                                      Switzerland
                      Spain
                                                                                            UEFA Nations League
                                                                                                             Santa Cruz de Tenerife S
                                                                                            UEFA Nations League
       3 2024-10-15
                      Spain
                                        Serbia
                                                                                            UEFA Nations League
                                                                                                              Cordoba
```

UEFA Nations League

UEFA Nations League

Geneva

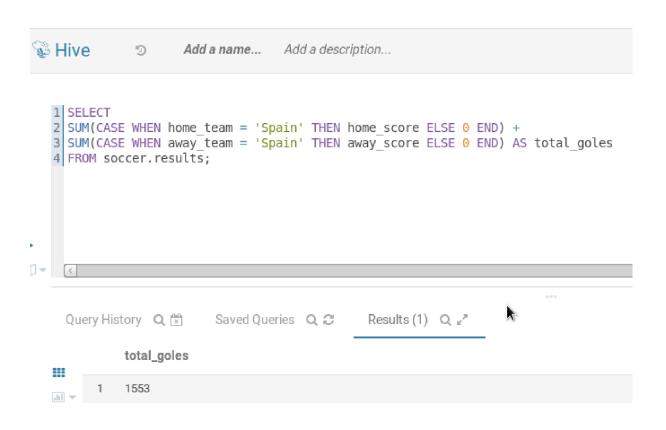
4 2024-10-12

5 2024-09-08 Switzerland

Spain

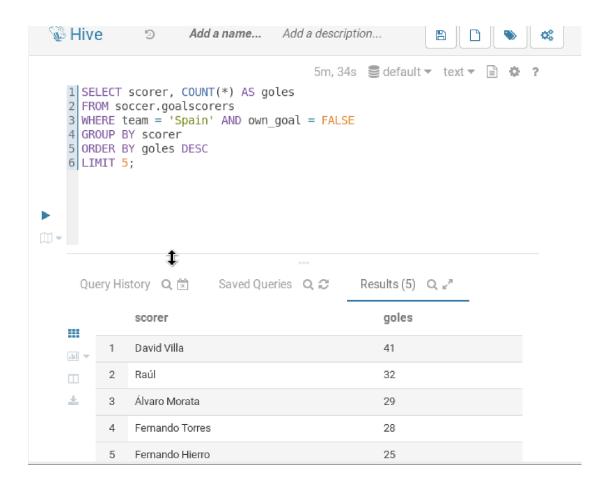
2.3 Número de goles que ha marcado España en toda su historia. Esta información debe extraerse de results, ya que goalscorers no contiene todos los goles.

```
SELECT
SUM(CASE WHEN home_team = 'Spain' THEN home_score ELSE 0 END) +
SUM(CASE WHEN away_team = 'Spain' THEN away_score ELSE 0 END) AS
total_goles
FROM soccer.results;
```



2.4 Listado de los 5 máximos goleadores con la selección española (sin contar autogoles).

```
SELECT scorer, COUNT(*) AS goles
FROM soccer.goalscorers
WHERE team = 'Spain' AND own_goal = FALSE
GROUP BY scorer
ORDER BY goles DESC
LIMIT 5;
```



2.5 Listado de los jugadores españoles que han marcado algún gol de penalti en alguna Eurocopa (UEFA Euro), ordenados alfabéticamente.

```
SELECT DISTINCT g.scorer AS jugador

FROM soccer.goalscorers g

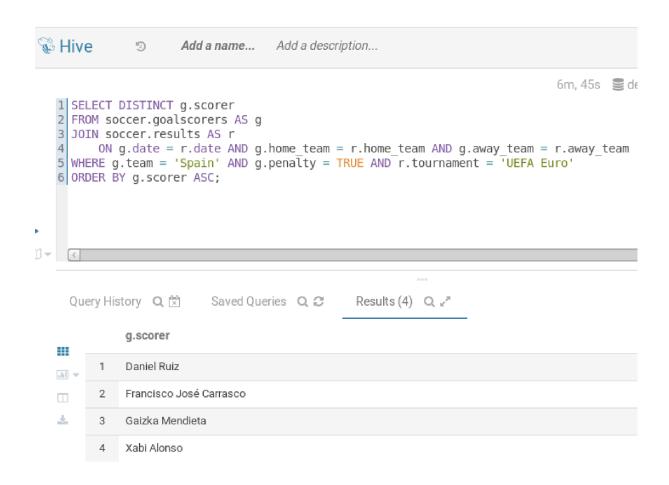
JOIN soccer.results r

ON g.date = r.date AND g.home_team = r.home_team AND g.away_team = r.away_team

WHERE g.team = 'Spain'

AND g.penalty = TRUE

AND r.tournament = 'UEFA Euro'
ORDER BY jugador ASC;
```



2.6 Listado de los 5 máximos goleadores de las fases finales de los Mundiales (FIFA World Cup) (sin contar autogoles).

```
SELECT g.scorer, COUNT(*) AS goles
FROM soccer.goalscorers AS g
INNER JOIN soccer.results AS r
     ON r.date = g.date
WHERE g.own goal=FALSE AND r.tournament = 'FIFA World Cup'
GROUP BY q.scorer
ORDER BY goals DESC
LIMIT 5;
```

7m, 33 1 SELECT g.scorer, COUNT(*) AS goles 2 FROM soccer.goalscorers AS g 3 INNER JOIN soccer.results AS r ON r.date = g.date5 WHERE g.own goal = FALSE AND r.tournament = 'FIFA World Cup' 6 GROUP BY g.scorer ORDER BY goles DESC 8 LIMIT 5;

Query History Q 🖄 Saved Queries Q 🗸 goles g.scorer Just Fontaine 60 all v 2 Gerd Müller 49 土 3 Helmut Rahn 44 4 Uwe Seeler 44 5 Miroslav Klose 43

Results (5) Q 2

APARTADO 2

En la tarea del entregable 2 trabajamos con el conjunto de datos de películas y series de la plataforma Amazon Prime, publicado en Kaggle por OctopusTeam. Además de Amazon Prime, OctopusTeam también publica el conjunto de datos de las otras principales plataformas de streaming:

- Netflix
- Apple TV+
- Amazon Prime
- Hulu
- HBO Max

Debes descargar el archivo de cada plataforma e importar los datos en una tabla Hive, utilizando 5 particiones estáticas, una para cada plataforma.

Solo se deben tener en cuenta aquellas series o películas que están registradas en IMDB (tienen un imdbld). Puedes eliminar las otras filas directamente de los archivos de datos, antes de hacer la carga.

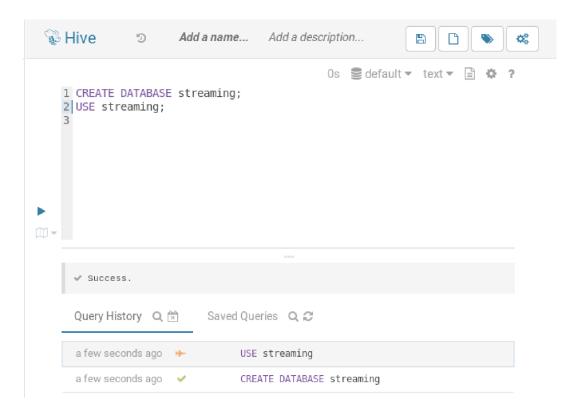
Si una serie o película está disponible en varias plataformas, podemos considerarlas como series o películas diferentes.

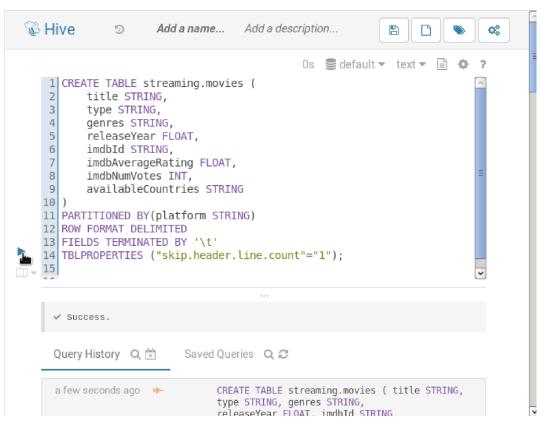
Recuerda que el campo type nos indica si se trata de una película (movie) o una serie (tv).

1 - Importación de datos:

He decidido descargar los archivos csv en mi ordenador local, formatearlos y después de esto ya están listos para trabajar con ellos. Para enviarlos a la máquina virtual he usado el comando *scp* apuntando al directorio que me interesa

Una vez hecho esto para cada archivo podemos crear la base de datos, las tablas y empezar a cargar los datos en Hive.





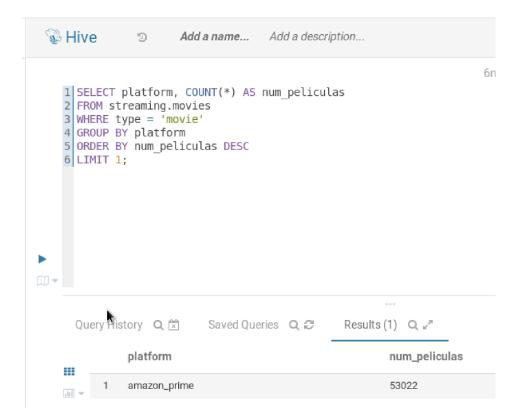
```
1 LOAD DATA LOCAL INPATH 'home/cloudera/tarea_3/apartado_2/amazon.csv'
    2 INTO TABLE streaming.movies
    3 PARTITION(platform = 'amazon prime');
    5 LOAD DATA LOCAL INPATH 'home/cloudera/tarea_3/apartado_2/apple.csv'
    6 INTO TABLE streaming.movies
    7 PARTITION(platform = 'apple_tv');
    9 LOAD DATA LOCAL INPATH 'home/cloudera/tarea 3/apartado 2/hbo.csv'
    10 INTO TABLE streaming.movies
    11 PARTITION(platform = 'hbo max');
   13 LOAD DATA LOCAL INPATH 'home/cloudera/tarea 3/apartado 2/hulu.csv'
    14 INTO TABLE streaming.movies
D = 15 PARTITION(platform = 'hulu');
     ✓ Success.
     Query History Q 🛱
                        Saved Queries Q 2
                             LOAD DATA LOCAL INPATH 'home/cloudera/tarea_3/apartado_2/hulu.csv' INTO TABLE streaming.movies PARTITION(platform = 'hulu')
     a few seconds ago 💙
 CREATE DATABASE streaming;
 USE streaming;
 CREATE TABLE streaming.movies (
       title STRING,
       type STRING,
       genres STRING,
       releaseYear FLOAT,
       imdbId STRING,
       imdbAverageRating FLOAT,
       imdbNumVotes INT,
       availableCountries STRING
 )
 PARTITIONED BY (platform STRING)
 ROW FORMAT DELIMITED
 FIELDS TERMINATED BY '\t'
 TBLPROPERTIES ("skip.header.line.count"="1");
```

```
LOAD DATA LOCAL INPATH
  '/home/cloudera/tarea 3/apartado 2/amazon.csv' INTO TABLE
  streaming.movies
PARTITION(platform = 'amazon prime');
LOAD DATA LOCAL INPATH
  '/home/cloudera/tarea_3/apartado_2/apple.csv' INTO TABLE
  streaming.movies
PARTITION(platform = 'apple_tv');
LOAD DATA LOCAL INPATH
  '/home/cloudera/tarea 3/apartado 2/hbo.csv' INTO TABLE
  streaming.movies
PARTITION(platform = 'hbo max');
LOAD DATA LOCAL INPATH
   '/home/cloudera/tarea 3/apartado 2/hulu.csv' INTO TABLE
  streaming.movies
PARTITION(platform = 'hulu');
LOAD DATA LOCAL INPATH
  '/home/cloudera/tarea 3/apartado 2/netflix.csv' INTO TABLE
  streaming.movies
PARTITION(platform = 'netflix');
```

2 - Querys:

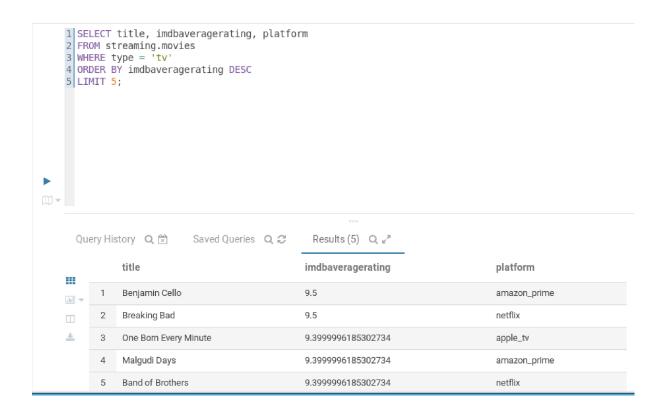
2.1 ¿Cuál de las plataformas tiene más películas en su colección? Muestra la plataforma y el número de películas.

```
SELECT platform, COUNT(*) AS num_peliculas
FROM streaming.movies
WHERE type = 'movie'
GROUP BY platform
ORDER BY num_peliculas DESC
LIMIT 1;
```



2.2 ¿Cuál de las plataformas tiene más películas en su colección? Muestra la plataforma y el número de películas.

```
SELECT title, imdbaveragerating, platform
FROM streaming.movies
WHERE type = 'tv'
ORDER BY imdbaveragerating DESC
LIMIT 5;
```



2.3 ¿Cuál de las plataformas tiene más películas en su colección? Muestra la plataforma y el número de películas.

```
SELECT platform, SUM(imdbNumVotes) AS total_votos
 FROM streaming.movies
 WHERE genres LIKE '%Sci-Fi%'
     OR genres LIKE '%Science Fiction%'
     AND type = 'tv'
 GROUP BY platform
 ORDER BY total votos DESC;
    1 SELECT platform, SUM(imdbNumVotes) AS total votos
    2 FROM streaming.movies
    3 WHERE type = 'tv' AND genres LIKE '%Sci-Fi%' OR genres LIKE '%Science Fiction%'
    4 GROUP BY platform
5 ORDER BY total_votos DESC;
∭ ▼
     Query History Q 🖄 Saved Queries Q 🗸
                                              Results (5) Q 2
             platform
                                                          total_votos
    ...
                                                          3403767
             amazon_prime
    dd w
                                                          2375367
          2
             apple_tv
    Ł
             netflix
          3
                                                          1665835
          4
             hulu
                                                          1551810
          5
             hbo_max
                                                          745275
```

2.4 ¿Cuál de las plataformas tiene más películas en su colección? Muestra la plataforma y el número de películas.

```
SELECT releaseyear, COUNT(*) AS num_peliculas
FROM streaming.movies
WHERE type = 'movie'
GROUP BY releaseYear
ORDER BY num_peliculas DESC
LIMIT 5;
```

